Predicción de captación de clientes en campañas de marketing bancario

Trabajo Práctico Final — Aprendizaje Artificial

Maestría en Gestión y Desarrollo de Inteligencia Artificial · Universidad CAECE

Docentes: Juan Azcurra · Paul Pablo Hernán

Autor: Fernando Caceres

Fecha: 23/10/2026

Resumen ejecutivo

El trabajo construye un modelo que **ordena a los clientes potenciales según su probabilidad de convertirse en clientes del banco**, para decidir a quién contactar en una campaña telefónica con presupuesto limitado. Se siguió la metodología CRISP-DM de punta a punta: comprensión del negocio y de los datos, preparación, modelado, evaluación y despliegue.

Tratamiento de los datos. Durante la inspección se detectó que **las 4.521 filas del archivo de test estaban contenidas en el archivo de entrenamiento** (el dataset *Bank Marketing* de UCI distribuye `bank.csv` como una muestra de `bank-full.csv`). Esas filas se eliminaron del entrenamiento, que quedó en 40.690 registros, para que la evaluación final se hiciera sobre datos no vistos.

Modelo pre-contacto. Se excluyó la variable `duration` (duración de la llamada): solo se conoce después de llamar, por lo que usarla constituiría una fuga de información.

Modelos comparados. Se compararon diez algoritmos de distintas familias con el mismo protocolo de validación cruzada estratificada de 5 folds. También se evaluaron:

- tres estrategias de desbalance;
- dos codificaciones de variables categóricas;
- un ajuste de hiperparámetros con Optuna.

Modelo elegido. Mediante una matriz de decisión ponderada se eligió **LightGBM** sin tratamiento de desbalance y con categorías nativas. Obtuvo en validación cruzada:

- PR-AUC de 0,466 ± 0,020;
- ROC-AUC de 0,806.

Resultados en el hold-out (4.521 clientes, evaluado una única vez):

Métrica	Modelo final	Regresión logística	Azar
ROC-AUC	0,784	0,738	—
PR-AUC	0,435	0,349	0,115

Estos valores están dentro del rango de referencia para este dataset sin `duration` (0,75–0,80).

Lectura de negocio:

- Contactando al 10 % de clientes mejor rankeado se captura el 42,2 % de las conversiones, con un lift de 4,21.
- Contactando al 20 % se captura el 59,7 %.
- Con los supuestos económicos adoptados (valor de una conversión = 20 veces el costo de una llamada), el umbral de máximo beneficio es 0,050. Con él se contacta al 61,1 % de los clientes y se captura el 86,6 % de las conversiones.
- El beneficio esperado supera en 6,1 % al de contactar a todos.
- El valor del modelo crece cuando la llamada es más cara en relación con la conversión: con un ratio 10:1 el modelo triplica el beneficio de la estrategia de contactar a todos.

Explicabilidad y despliegue:

- La explicabilidad (SHAP, regresión logística y un árbol de reglas) coincide en las variables clave: el mes del contacto, el canal, el saldo, la tenencia de préstamos y el éxito en campañas anteriores.
- El modelo se despliega mediante una API REST (FastAPI) y una interfaz web (Streamlit) que permiten puntuar clientes individuales o listados completos.

1. Comprensión del negocio

1.1 Problema y decisión

Un banco realiza campañas de marketing telefónico para captar clientes para un depósito a plazo. Cada contacto tiene un costo y solo una minoría de los contactados se convierte (11,72 % en los datos de entrenamiento).

La decisión que apoya el modelo es la siguiente:

> ***Dado un listado de clientes potenciales y un presupuesto de contactos, ordenarlos según su***
>
> ***probabilidad de conversión y contactar a los primeros k.***

Por lo tanto, el modelo se evalúa principalmente como una **herramienta de ranking**. La decisión binaria (llamar o no llamar) surge de aplicar un umbral económico sobre la probabilidad estimada.

1.2 Restricción: información disponible antes del contacto

El modelo se utiliza **antes** de llamar. En consecuencia, se excluye toda variable que solo se conoce después del contacto. El caso central es `duration`:

- la duración de la llamada se conoce al finalizarla;
- además, es en buena medida *consecuencia* del interés del cliente.

El modelo entregable se denomina **modelo pre-contacto**. Se entrenó una variante con `duration` exclusivamente para cuantificar el efecto de esa fuga (sección 5.5).

1.3 Métricas

Tipo	Métrica	Justificación
Primaria	PR-AUC (average precision)	Resume la calidad del ranking sobre la clase minoritaria; su valor al azar es la prevalencia (~0,117)
Primaria	Lift y gain en el top 10 %, 20 % y 30 %	Traducen el ranking a la decisión: qué proporción de las conversiones se captura contactando a una fracción de los clientes
Secundaria	ROC-AUC	Permite contrastar con la literatura
Secundaria	Precision, recall y F1 al umbral operativo	Describen la decisión binaria
Secundaria	Brier y curva de calibración	Verifican que las probabilidades puedan interpretarse como tales, lo cual es necesario para el cálculo económico

Por qué no accuracy. Con 88,3 % de clientes que no se convierten, un modelo que responde siempre "no" alcanza 88,3 % de accuracy sin identificar a ningún cliente. Accuracy premia acertar la clase mayoritaria, mientras que el valor de negocio está en encontrar a la minoría que se convierte.

1.4 Marco económico

Se definió un costo por contacto **C = 1** y un valor esperado por conversión **V = 20**. El beneficio esperado de contactar a un conjunto de clientes es:

$$Beneficio = V \cdot TP - C \cdot (TP + FP)$$

Contactar a un cliente con probabilidad p conviene si $p \cdot V > C$, es decir, si $p > C/V = 0{,}05$.

Los valores C y V son **supuestos ilustrativos**; lo relevante es su cociente. Por ello se analiza la sensibilidad para V/C = 5, 10, 20 y 50. El banco puede reemplazarlos por valores reales:

- **C**: costo del operador, de la telefonía y del desgaste por contacto;
- **V**: margen neto del producto más el valor de vida del cliente.

Ambos valores se modifican en `config.py` y el pipeline recalcula el umbral y el análisis económico.

2. Comprensión de los datos

2.1 Archivos y verificaciones

Archivos recibidos:

Archivo	Equivale a	Filas	Tasa de conversión
`banca_train.csv`	`bank-full.csv`	45.211	11,70 %
`banca_test.csv`	`bank.csv`	4.521	11,52 %

Ambos archivos tienen 17 columnas, separador `;` y encoding ASCII. Los datos corresponden al dataset *Bank Marketing* (Moro, Cortez y Rita, 2014; UCI Machine Learning Repository), con campañas realizadas entre mayo de 2008 y noviembre de 2010.

Verificaciones realizadas:

- El esquema coincide con el diccionario de la consigna.
- No hay valores nulos ni duplicados exactos dentro de cada archivo.

Hallazgo crítico: solapamiento.

- Una comparación fila por fila mostró que las 4.521 filas de test (100 %) aparecen idénticas en train.
- Utilizar los archivos tal como fueron entregados habría implicado evaluar el modelo sobre datos vistos durante el entrenamiento.
- Esas filas se eliminaron del conjunto de entrenamiento, que quedó en 40.690 registros (4.768 conversiones, 11,72 %).
- El proceso completo está registrado en la tabla 1 y en `docs/03_preparacion_datos.md`.

Naturaleza de la partición. El archivo de entrenamiento está ordenado cronológicamente, por lo que se verificó si el test correspondía a un período posterior:

- Las posiciones de las filas de test dentro del archivo son compatibles con una distribución uniforme (Kolmogorov-Smirnov D = 0,014, p = 0,37).
- Las distribuciones de mes, canal, resultado previo y target no difieren entre ambos conjuntos (χ^2 con p = 0,47, 0,54, 0,20 y 0,72).
- Conclusión: la partición es **aleatoria**, y se valida con validación cruzada estratificada.

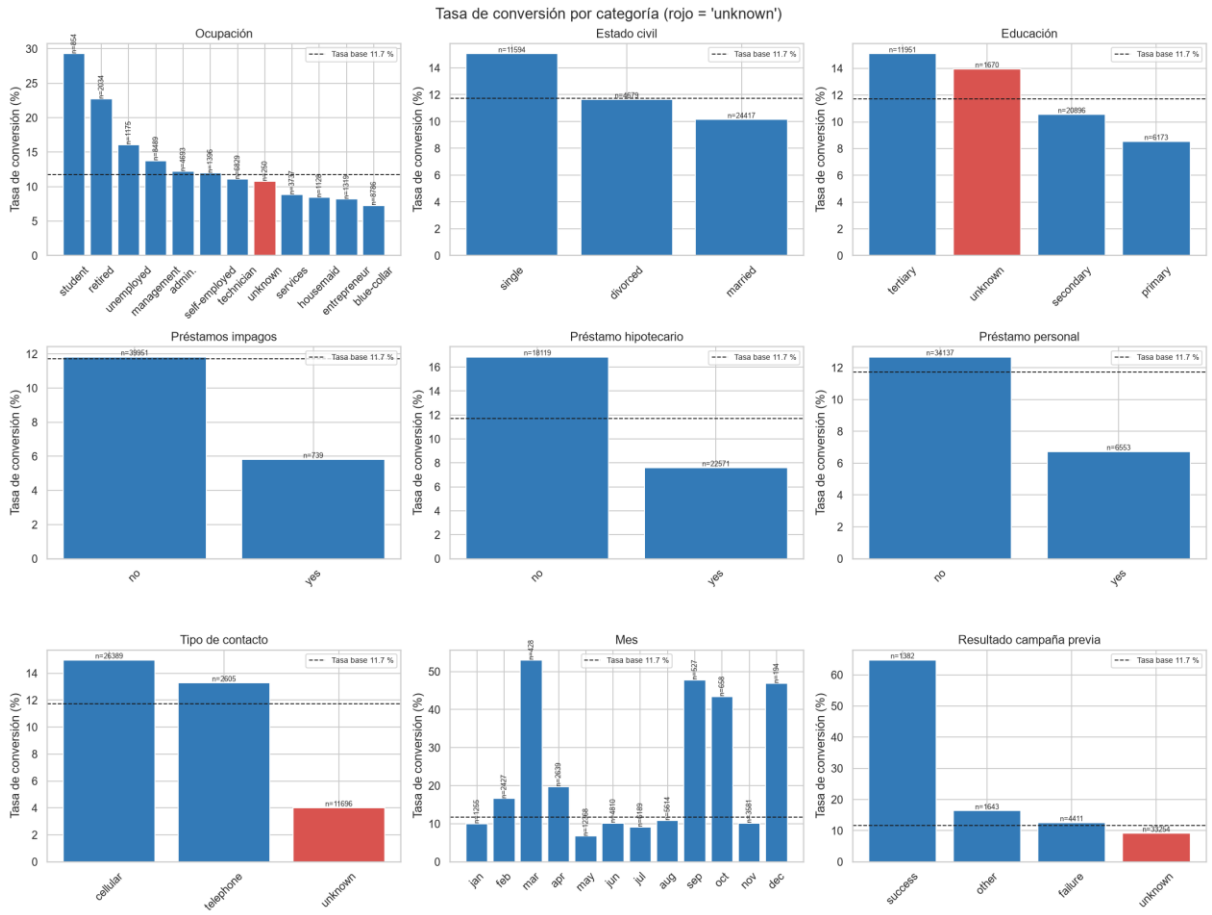
Tabla 1. Registro de operaciones sobre filas.

#	Paso	Conjunto	Filas antes	Filas después	Detalle
1	load	train	45.211	45.211	banca_train.csv leído con sep=';' y encoding ASCII; esquema validado (17 columnas).
2	load	test	4.521	4.521	banca_test.csv leído con sep=';' y encoding ASCII; esquema validado (17 columnas).
3	check_exact_duplicates	train	45.211	45.211	Duplicados exactos dentro de train: 0. No se elimina nada.
4	check_exact_duplicates	test	4.521	4.521	Duplicados exactos dentro de test: 0. No se elimina nada.
5	check_nulls	train+test	49.732	49.732	Nulos: train=0, test=0. Los faltantes vienen codificados como la categoría 'unknown' y

					pdays=-1.
6	remove_train_test_overlap	train	45.211	40.690	4521 de 4521 filas de test (100.0 %) aparecen idénticas en train (bank.csv es una muestra de bank-full). Se quitan de train para que el hold-out sea independiente.
7	save_processed	train	40.690	40.690	Guardado en data/processed/train_clean.csv (sin transformar variables).
8	save_processed	test	4.521	4.521	Guardado en data/processed/test_clean.csv (idéntico al original).

2.2 Análisis exploratorio

El análisis exploratorio se realizó solo sobre el conjunto de entrenamiento limpio (`notebooks/01_eda.ipynb`).



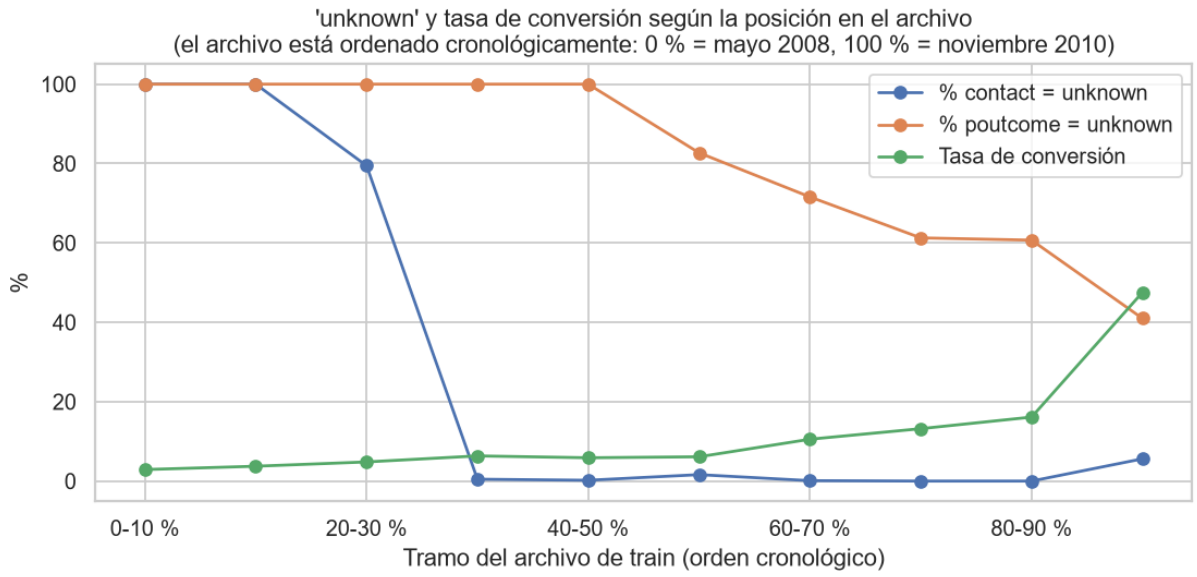
Tasa de conversión por categoría

Valores unknown. No constituyen faltantes aleatorios:

- **contact = unknown** (28,7 % de los registros):
  - convierte 4,0 % frente a 14,8 % del resto;
  - ocupa el 100 % del primer 20 % del archivo, es decir, corresponde a un período sin registro del canal.

- **poutcome = unknown** (81,7 %) equivale a "nunca contactado en una campaña previa".
- **education = unknown** convierte 14,0 %, más que la moda.

En consecuencia, se mantienen como una categoría propia.



Unknown y conversión a lo largo del archivo

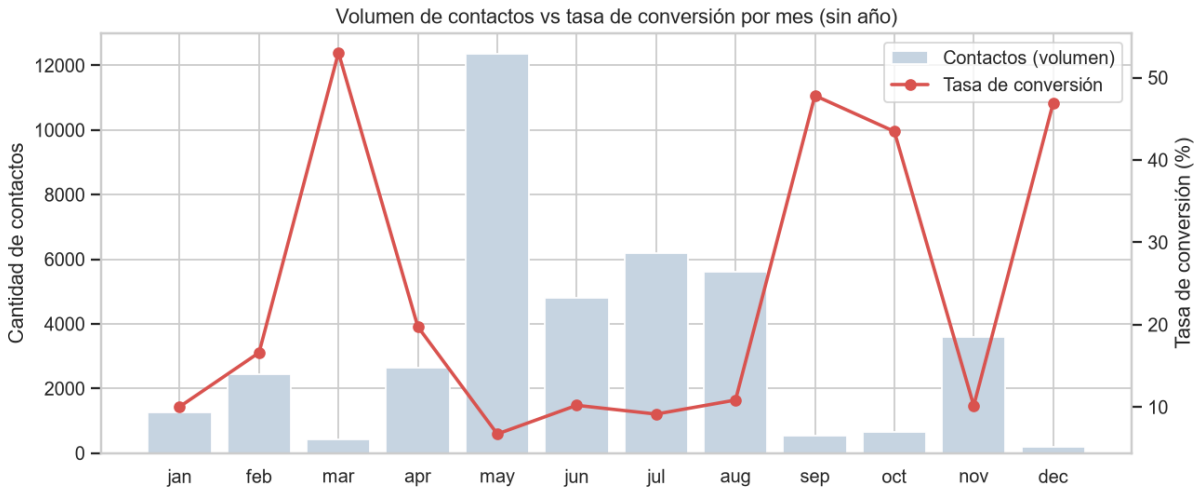
pdays = -1. Las 33.249 filas con `pdays = -1` (81,7 %) son exactamente las que tienen `previous = 0` y `poutcome = unknown`. El valor -1 es un código, no una cantidad de días. Tasas de conversión:

- nunca contactados: 9,2 %;
- contactados en una campaña previa: 23,1 %;
- con resultado previo exitoso: **64,8 %**.

Mes y volumen.

- Mayo concentra el 30,4 % de los contactos con una tasa de 6,7 %.
- Los meses con pocas llamadas (marzo, septiembre, octubre, diciembre) superan el 40 %.
- La correlación de Spearman entre volumen y tasa es -0,84.

El efecto refleja la operación del banco y el período, más que una estacionalidad del cliente.



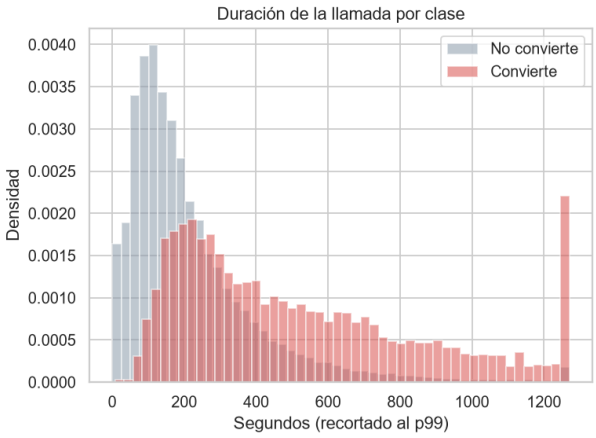
Volumen y conversión por mes

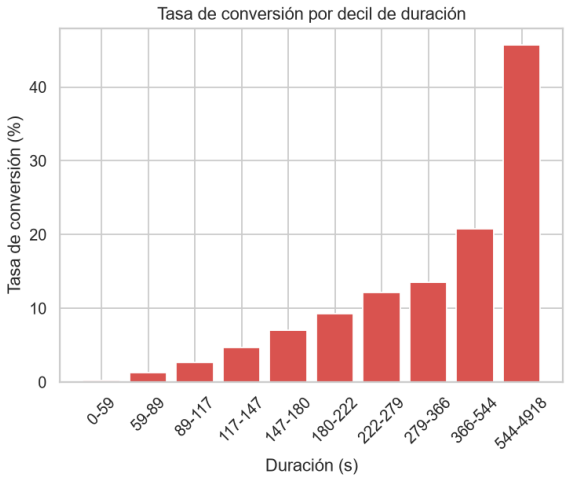
Outliers:

- **balance**:
  - varía entre -8.019 y 102.127, con asimetría 8,5 y 10,4 % de outliers según la regla IQR;
  - tiene 8,4 % de saldos negativos y 7,8 % de saldos nulos;
  - son valores reales, por lo que se transforman en lugar de eliminarse.
- **campaign**:
  - llega a 63 contactos (p99 = 17);
  - la conversión cae de 14,7 % con un contacto a 6,4 % con cinco o más.

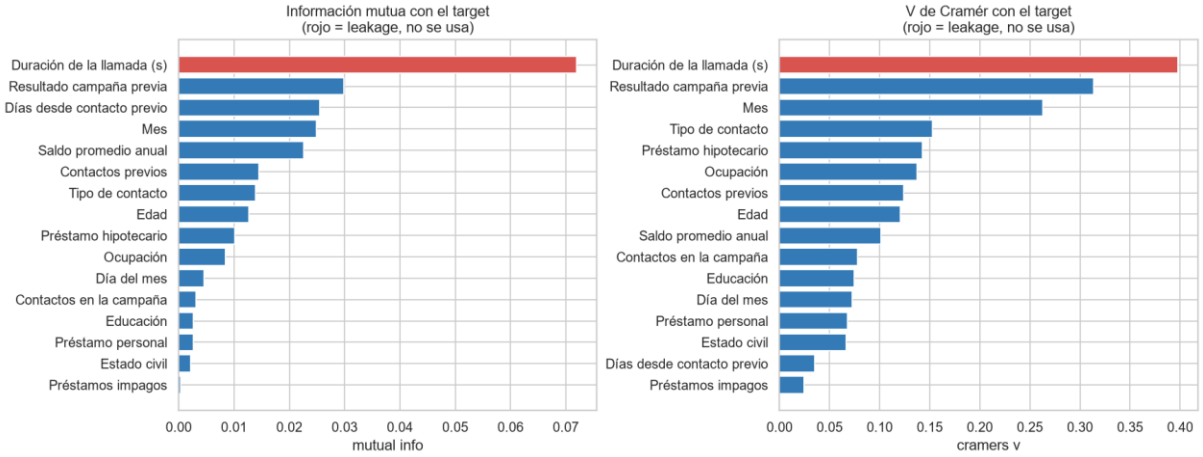
duration como leakage:

- Por sí sola alcanza un ROC-AUC de 0,807.
- La mediana es de 164 s en los que no se convierten y de 424 s en los que se convierten.
- Las llamadas de menos de 60 s convierten 0,2 %.
- Hay 3 llamadas con duración 0.





Duration como leakage



Ranking preliminar de variables

3. Preparación de los datos

Todas las transformaciones de columnas se implementaron dentro de un `Pipeline` de scikit-learn o imbalanced-learn. Esto tiene dos consecuencias:

- en cada fold de validación se ajustan únicamente con los datos de entrenamiento, lo que evita fugas de información;
- el modelo final guardado recibe los datos crudos y aplica exactamente las mismas transformaciones.

Tabla 2. Variables derivadas y su justificación.

Variable	Origen	Transformación	Justificación
age	age	Sin cambios	Edad numérica.
age_group	age	Bins <25, 25-34, 35-44, 45-54, 55-64, 65+	Efecto no lineal: conversión alta en jóvenes y mayores de 60.
balance_log	balance	sign(x)·log(1+	x
balance_negative	balance	1 si balance < 0	8,4 % de clientes en descubierto.
balance_zero	balance	1 si balance = 0	7,8 % de clientes sin saldo.
campaign_w	campaign	Winsorizado al p99 del fold de entrenamiento	Cola larga (máx. 63); el p99 se aprende en fit para no usar información del fold de validación.
previous_w	previous	Winsorizado al p99 del fold de entrenamiento	Cola larga; mismo criterio que campaign.
pdays_clean	pdays	NaN cuando pdays = -1	El -1 no es un número de días; el faltante se imputa luego según la familia de modelo.
previously_contacted	pdays	1 si pdays != -1	Conserva explícitamente la información 'nunca contactado' (23,1 % vs 9,2 % de conversión).
day_sin / day_cos	day	sin/cos(2π·day/31)	El día del mes es cíclico: el 31 está cerca del 1.
contact_known	contact	1 si contact != unknown	contact=unknown corresponde a un período sin registro del canal (4,0 % de conversión).
prev_campaign_success	poutcome	1 si poutcome = success	Señal más fuerte disponible antes de llamar (64,8 % de conversión).
season	month	Estación del año (hemisferio norte)	Agrupa meses de bajo volumen para estabilizar su estimación.
n_credit_products	housing, loan, default	Suma de yes en housing + loan + default	Tener préstamos reduce la conversión; resume la carga crediticia.
job, marital, education, default, housing, loan, contact, month, poutcome	originales	Categóricas sin cambios ('unknown' se mantiene como categoría)	unknown no es un faltante aleatorio (ver EDA).
duration	duration	Solo en el conjunto with_duration	Leakage: se conoce después de la llamada. Excluida del modelo entregable.

Preprocesamiento según la familia de modelo:

- **Modelos lineales, KNN, MLP y SVM**: imputación por mediana, estandarización y codificación one-hot (67 columnas).
- **Árboles y boosting**: sin escalado (son invariantes a transformaciones monótonas), con one-hot o con categorías nativas.
- **Naive Bayes categórico**: discretización en quintiles.

Decisiones deliberadas:

- no se imputaron los unknown;
- no se eliminaron outliers;
- no se utilizó duration.

El documento docs/03_preparacion_datos.md detalla cada operación.

4. Modelado

4.1 Protocolo

Se utilizó `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)` sobre los 40.690 registros. Todos los modelos usan exactamente la misma partición y se reporta la media ± el desvío estándar entre folds. El conjunto de test no interviene en ninguna decisión de esta fase.

4.2 Algoritmos y justificación

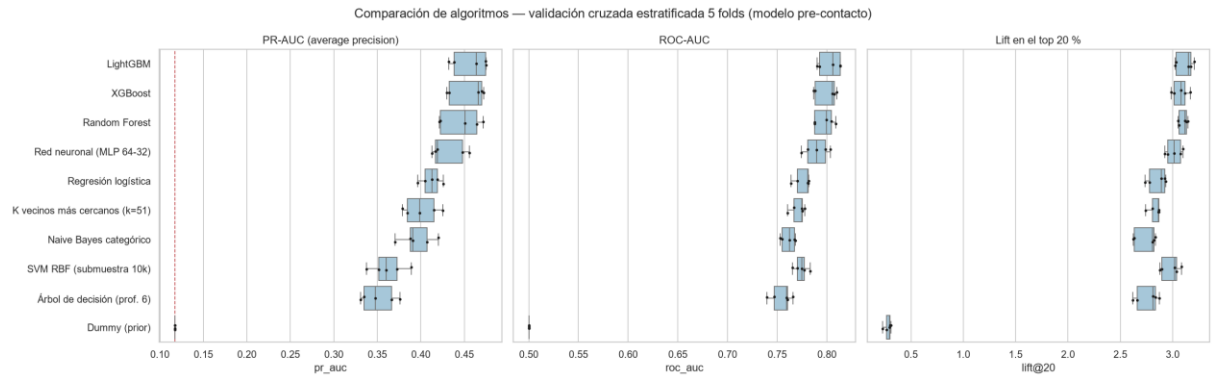
Se compararon diez algoritmos que representan las familias vistas en la materia:

Algoritmo	Familia	Por qué se incluye
Dummy (prior)	Referencia	Piso de comparación
Regresión logística	Lineal	Baseline interpretable
Árbol de decisión	Árboles	Genera reglas explicables
KNN (k = 51)	Basado en instancias	Clasificación por similitud
Naive Bayes categórico	Probabilístico	Modelo generativo
Random Forest	Bagging	Reduce varianza
LightGBM y XGBoost	Boosting	Estado del arte en datos tabulares
MLP	Redes neuronales	Representante de la familia
SVM RBF	Kernels	Frontera no lineal de máximo margen

La SVM se entrenó sobre una submuestra estratificada de 10.000 filas por su costo cuadrático.

Tabla 3. Resultados de validación cruzada (modelo pre-contacto).

Modelo	Familia	PR-AUC	ROC-AUC	Lift@20 %	Brier	Ajuste (s)
LightGBM	Ensamble (boosting)	0,457 ± 0,020	0,803 ± 0,011	3,12 ± 0,08	0,146	0,8
XGBoost	Ensamble (boosting)	0,454 ± 0,021	0,799 ± 0,011	3,07 ± 0,08	0,146	1,1
Random Forest	Ensamble (bagging)	0,446 ± 0,023	0,797 ± 0,010	3,10 ± 0,04	0,114	2,7
Red neuronal (MLP 64-32)	Redes neuronales	0,430 ± 0,020	0,789 ± 0,012	3,01 ± 0,07	0,083	1,4
Regresión logística	Lineal	0,412 ± 0,012	0,776 ± 0,008	2,85 ± 0,09	0,180	0,4
K vecinos más cercanos (k=51)	Basado en instancias	0,401 ± 0,020	0,771 ± 0,007	2,83 ± 0,06	0,085	0,1
Naive Bayes categórico	Probabilístico	0,395 ± 0,019	0,761 ± 0,007	2,74 ± 0,11	0,114	0,1
SVM RBF (submuestra 10k)	Márgenes / kernels	0,362 ± 0,020	0,774 ± 0,007	2,98 ± 0,09	n/a	2,7
Árbol de decisión (prof. 6)	Árboles	0,351 ± 0,020	0,754 ± 0,011	2,76 ± 0,11	0,184	0,2
Dummy (prior)	Referencia	0,117 ± 0,000	0,500 ± 0,000	0,28 ± 0,03	0,103	0,1



Comparación de algoritmos

Interpretación de los resultados:

- **Ensambles de árboles**: forman el grupo superior (PR-AUC 0,446–0,457), casi cuatro veces el valor del Dummy (0,117).
- **Regresión logística** (0,412): la brecha con los ensambles mide el valor de capturar no linealidades e interacciones.
- **KNN y Naive Bayes**: rinden menos. KNN se ve afectado por la alta dimensionalidad del one-hot y Naive Bayes por la suposición de independencia, dado que existen variables redundantes.
- **SVM**: presenta un ROC-AUC competitivo pero la peor PR-AUC entre los modelos no triviales; ordena peor la parte alta del ranking.

4.3 Codificación de categóricas y desbalance

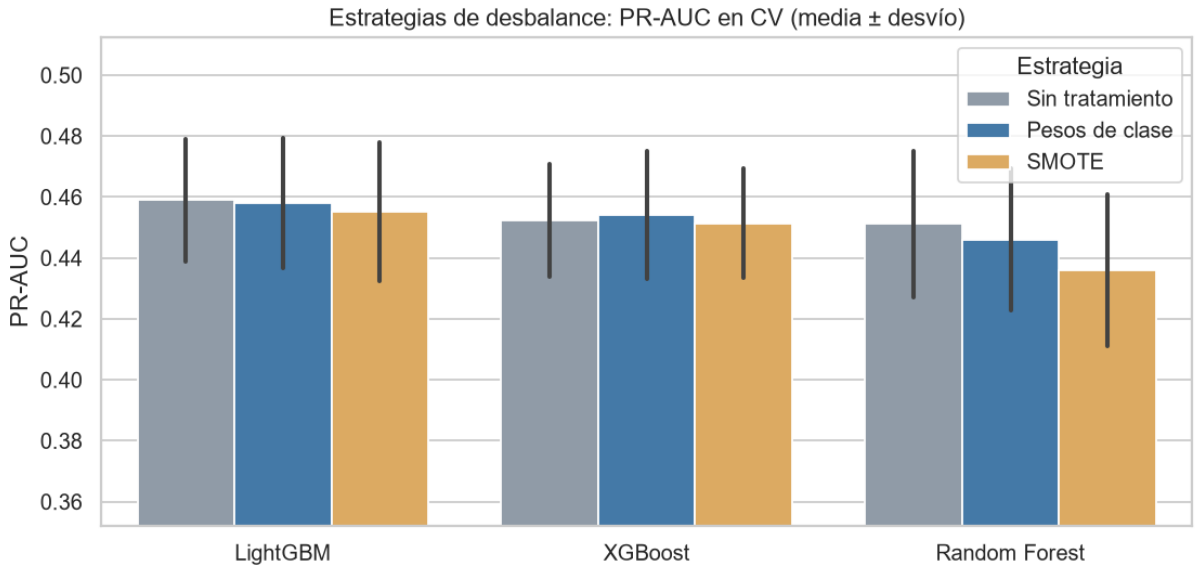
Tabla 4. Codificación en boosting.

Modelo	Codificación	PR-AUC	ROC-AUC
lightgbm	One-hot	0,457 ± 0,020	0,803
lightgbm	Nativa	0,458 ± 0,021	0,802
xgboost	One-hot	0,454 ± 0,021	0,799
xgboost	Nativa	0,451 ± 0,021	0,798

Codificación. Se eligió la codificación nativa para LightGBM y one-hot para XGBoost. La regla fue preferir la opción nativa salvo que la otra superara la PR-AUC en más de 0,003.

Tabla 5. Estrategias de desbalance sobre los tres mejores modelos.

Modelo	Estrategia	PR-AUC	ROC-AUC	Lift@20 %	Brier
lightgbm	Sin tratamiento	0,459 ± 0,020	0,804	3,12	0,081
lightgbm	Pesos de clase	0,458 ± 0,021	0,802	3,11	0,144
lightgbm	SMOTE	0,455 ± 0,023	0,802	3,11	0,082
xgboost	Sin tratamiento	0,452 ± 0,018	0,802	3,09	0,082
xgboost	Pesos de clase	0,454 ± 0,021	0,799	3,07	0,146
xgboost	SMOTE	0,451 ± 0,018	0,801	3,10	0,082
random_forest	Sin tratamiento	0,451 ± 0,024	0,799	3,13	0,082
random_forest	Pesos de clase	0,446 ± 0,023	0,797	3,10	0,114
random_forest	SMOTE	0,436 ± 0,025	0,794	3,07	0,087



Estrategias de desbalance

Desbalance. Las tres estrategias difieren en PR-AUC menos que un desvío estándar entre folds. Sin embargo:

- Los **pesos de clase descalibran** las probabilidades: el Brier de LightGBM pasa de 0,081 a 0,144.
- **SMOTE** genera clientes sintéticos por interpolación entre variables one-hot, lo cual carece de interpretación, y empeora al Random Forest.

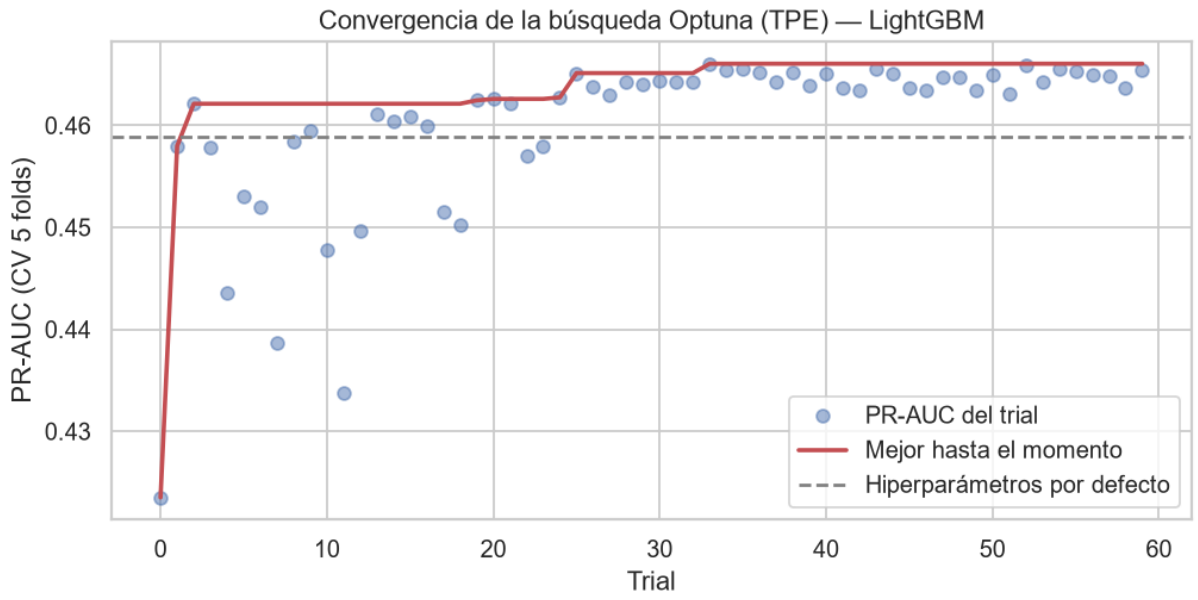
Como el umbral y el análisis económico requieren probabilidades calibradas, se eligió **no aplicar tratamiento y ajustar el umbral**.

4.4 Ajuste de hiperparámetros

Se utilizó Optuna con sampler TPE (semilla 42), 60 trials por modelo y un tope de 15 minutos por búsqueda. El objetivo fue la PR-AUC media en los mismos 5 folds.

Tabla 6. Resultados del tuning.

Modelo	Trials	Tiempo (s)	PR-AUC por defecto	PR-AUC tuneado	Mejores hiperparámetros
lightgbm	60	69	0,4589	0,4660	n_estimators=500, learning_rate=0,0117, num_leaves=44, min_child_samples=20, subsample=0,6797, colsample_bytree=0,6304, reg_lambda=0,0028, reg_alpha=0,0039
xgboost	60	71	0,4522	0,4629	n_estimators=500, learning_rate=0,0230, max_depth=8, min_child_weight=30,9075, subsample=0,9927, colsample_bytree=0,4401, reg_lambda=0,1119, gamma=0,0036



Convergencia Optuna LightGBM

Lectura:

- La mejora obtenida es pequeña: de 0,4589 a 0,4660 en LightGBM. El techo lo impone la información disponible antes del contacto, más que el algoritmo.
- La PR-AUC del mejor trial es levemente optimista, porque se seleccionó sobre los mismos folds. La estimación insesgada es la del conjunto de test.

4.5 Selección del modelo final

Criterios de la matriz de decisión (cada uno normalizado entre candidatos):

Criterio	Peso
PR-AUC	35 %
Lift@20 %	25 %
Estabilidad entre folds	15 %
Interpretabilidad	15 %
Velocidad de inferencia	10 %

Tabla 7. Matriz de decisión.

Candidato	PR-AUC	Desvío PR-AUC	Lift@20 %	Interpretab. (1-5)	ms / 1.000 filas	Puntaje ponderado
lightgbm_tuned	0,466	0,020	3,15	2	15,3	0,690
xgboost_tuned	0,463	0,025	3,12	2	6,9	0,667
xgboost_default	0,452	0,018	3,09	2	6,4	0,652
lightgbm_default	0,459	0,020	3,12	2	13,1	0,632
logreg_default	0,412	0,012	2,85	5	5,3	0,400

Resultado:

- Se seleccionó **LightGBM tuneado** (puntaje 0,690), con los siguientes hiperparámetros:

Hiperparámetro	Valor
Árboles	500
learning rate	0,0117
Hojas	44
min_child_samples	20
subsample	0,68
colsample_bytree	0,63

- La regresión logística (0,400) es la más estable e interpretable, pero pierde alrededor de 0,05 de PR-AUC. Se conserva como baseline y como contraste de explicabilidad.
- La menor interpretabilidad de LightGBM se compensa con SHAP.

4.6 Umbral operativo

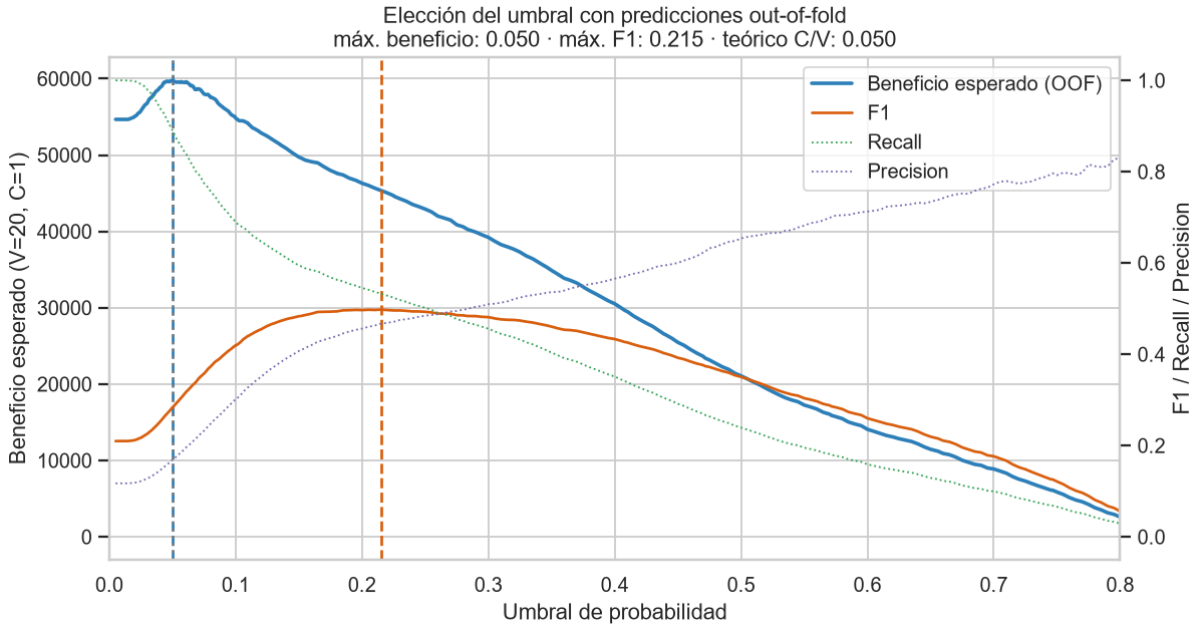
El umbral se eligió con las predicciones *out-of-fold* del modelo final, maximizando el beneficio esperado con V = 20 y C = 1.

Umbral de máximo beneficio: 0,050. Coincide con el umbral teórico C/V, lo que confirma probabilidades bien calibradas. Con este umbral:

- se contacta al 61,9 % de los clientes;
- el recall es 0,891;
- el beneficio es 59.772, frente a 54.670 si se contactara a todos.

Umbral de máximo F1: 0,215.

- Contacta solo al 13,4 % y reduce el beneficio a 45.363.
- F1 pondera por igual precision y recall, e ignora que una conversión vale veinte veces lo que cuesta una llamada.



Selección del umbral

Tabla 8. Sensibilidad del umbral al ratio V/C (predicciones OOF de train).

V/C	Umbral teórico C/V	Umbral óptimo OOF	% contactado	Recall	Beneficio modelo	Beneficio contactar a todos
5	0,200	0,165	15,9	0,582	7.377	-16.850
10	0,100	0,110	24,0	0,670	22.207	6.990
20	0,050	0,050	61,9	0,891	59.772	54.670
50	0,020	0,023	97,0	0,996	197.885	197.710

5. Evaluación y análisis

5.1 Resultados en el hold-out

Condiciones de la evaluación:

- El modelo, los hiperparámetros y el umbral quedaron fijados antes de leer el conjunto de test.
- La evaluación se realizó **una única vez** (`reports/tables/holdout_usage.json`).
- El umbral de la regresión logística también se eligió con sus propias predicciones *out-of-fold*.

Tabla 9. Métricas en test.

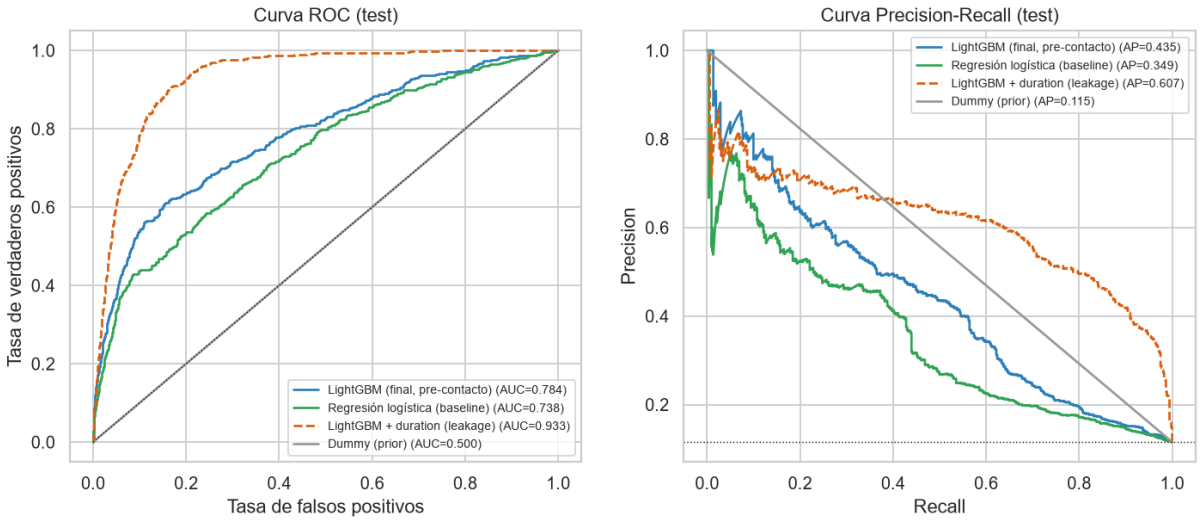
Modelo	ROC-AUC	PR-AUC	Lift@10 %	Lift@20 %	Gain@20 %	Brier	Umbral	Precision	Recall	F1
LightGBM (final, pre-contacto)	0,784	0,435	4,21	2,98	59,7 %	0,082	0,050	0,163	0,866	0,275
Regresión logística (baseline)	0,738	0,349	3,81	2,45	49,1 %	0,183	0,275	0,145	0,900	0,250
Dummy (prior)	0,500	0,115	1,09	0,99	19,8 %	0,102	0,050	0,115	1,000	0,207
LightGBM + duration (leakage)	0,933	0,607	5,48	4,16	83,3 %	0,062	0,050	0,326	0,969	0,488

Tabla 10. Validación cruzada vs test (modelo final).

Métrica	CV (media ± desvío)	Test
roc_auc	0,806 ± 0,010	0,784
pr_auc	0,466 ± 0,020	0,435
lift@10	4,401 ± 0,157	4,214
lift@20	3,152 ± 0,070	2,982
lift@30	2,386 ± 0,047	2,257
gain@20	0,631 ± 0,014	0,597
brier	0,081 ± 0,002	0,082

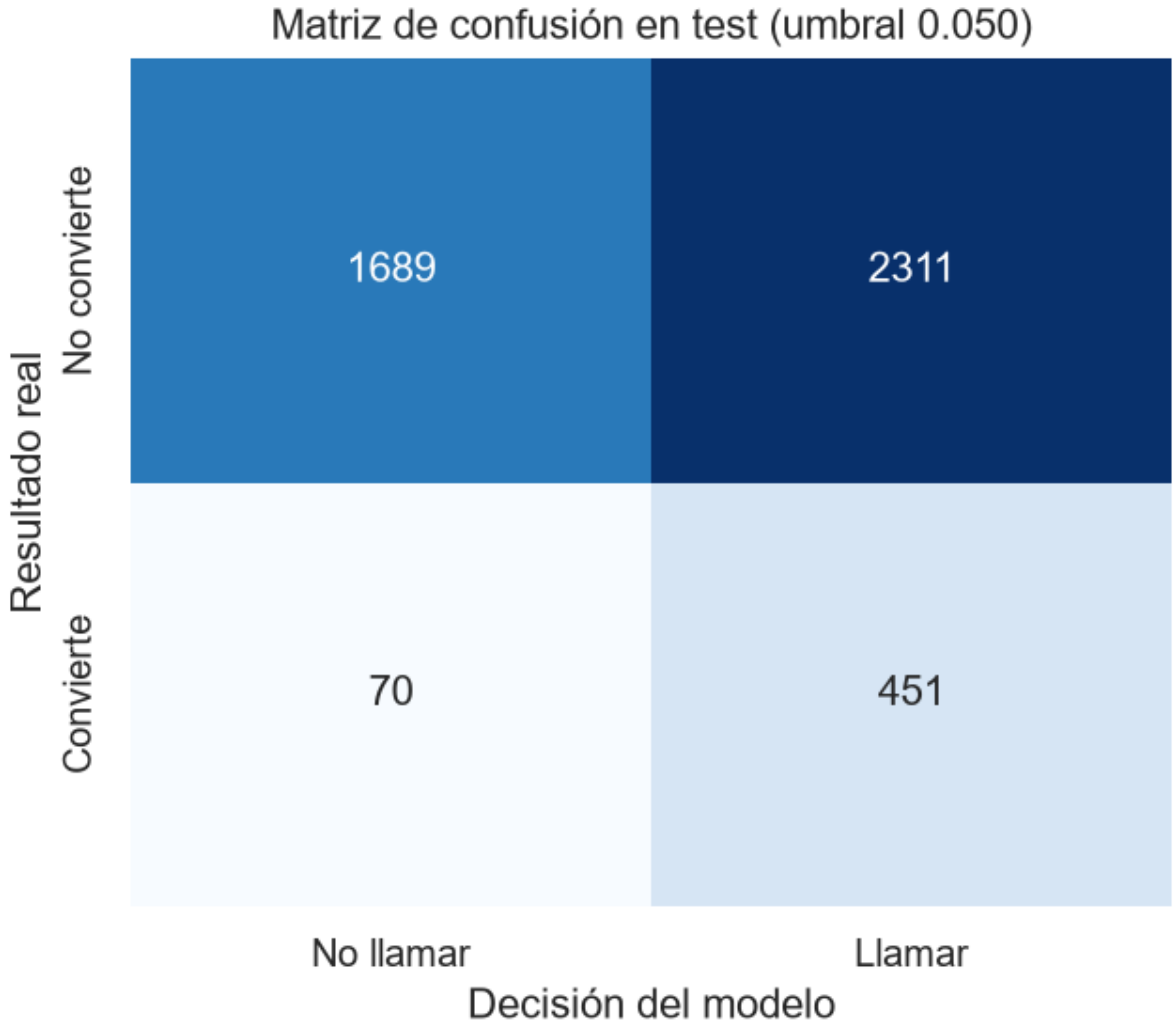
La PR-AUC en test es -0,031 menor que en validación cruzada. La diferencia está dentro de dos desvíos y es esperable por dos razones:

- el leve optimismo del tuning;
- el menor tamaño del test (521 conversiones).



Curvas ROC y PR

5.2 Decisión al umbral operativo



Matriz de confusión

Resultados con umbral 0,050:

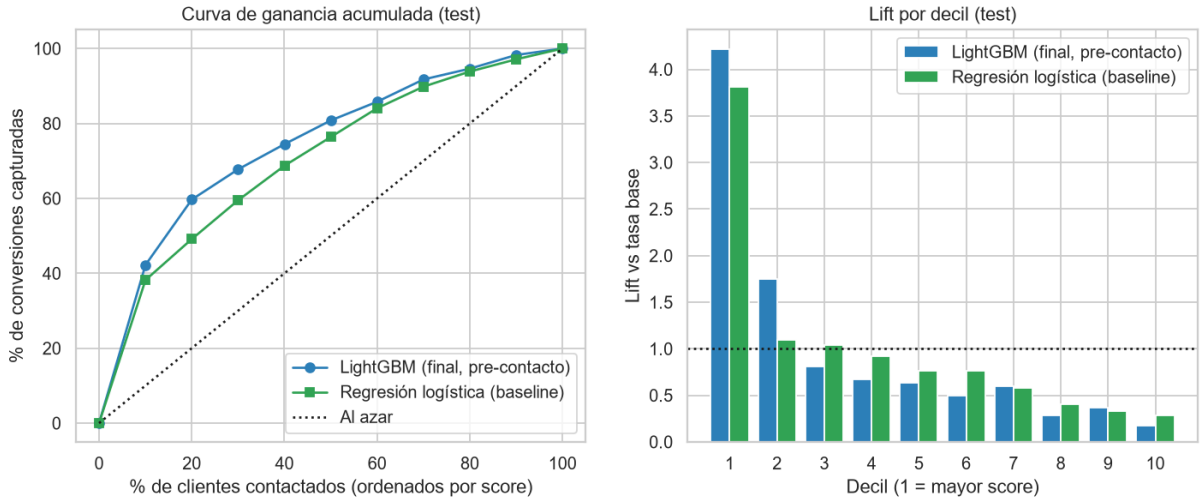
- el modelo recomienda contactar al 61,1 % de los clientes;
- captura 451 de las 521 conversiones (recall 86,6 %, precision 16,3 %);
- genera 2.311 falsos positivos y 70 falsos negativos.

Los falsos positivos son aceptables por diseño: una llamada sin conversión cuesta 1 y una conversión perdida cuesta 20.

5.3 Ranking, deciles y beneficio

Tabla 11. Deciles en test (decil 1 = mayor probabilidad).

Decil	Clientes	Conversiones	Tasa	Lift	% contactado acum.	Gain acumulado	Lift acumulado
1	453	220	48,6 %	4,21	10 %	42,2 %	4,21
2	452	91	20,1 %	1,75	20 %	59,7 %	2,98
3	452	42	9,3 %	0,81	30 %	67,8 %	2,26
4	452	35	7,7 %	0,67	40 %	74,5 %	1,86
5	452	33	7,3 %	0,63	50 %	80,8 %	1,62
6	452	26	5,8 %	0,50	60 %	85,8 %	1,43
7	452	31	6,9 %	0,60	70 %	91,7 %	1,31
8	452	15	3,3 %	0,29	80 %	94,6 %	1,18
9	452	19	4,2 %	0,36	90 %	98,3 %	1,09
10	452	9	2,0 %	0,17	100 %	100,0 %	1,00



Gain y lift

Tabla 12. Traducción a negocio (test, V = 20, C = 1).

Estrategia	Contactos	% contactado	Conversiones	% de conversiones capturadas	Beneficio (V=20, C=1)	vs contactar a todos
Top 10 % del ranking	453	10,0 %	220	42,2 %	3.947	-1.952
Top 20 % del ranking	905	20,0 %	311	59,7 %	5.315	-584
Top 30 % del ranking	1.357	30,0 %	353	67,8 %	5.703	-196
Umbral	2.762	61,1 %	451	86,6 %	6.258	359

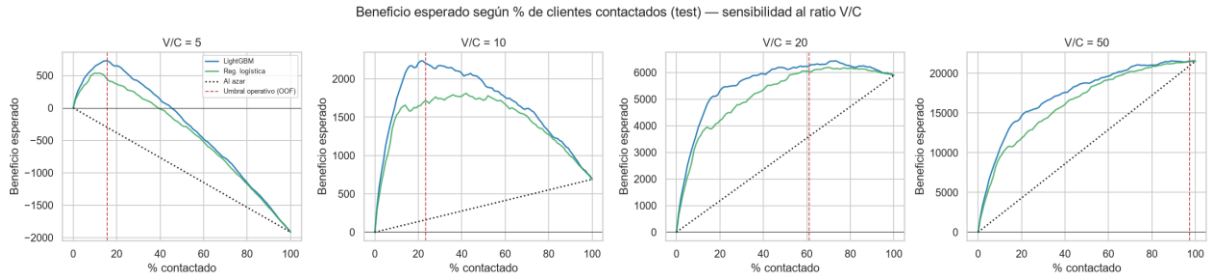
operativo (0.050)						
Contactar a todos	4.521	100,0 %	521	100,0 %	5.899	0
No contactar a nadie	0	0,0 %	0	0,0 %	0	-5.899

Lectura de negocio:

- **Top 10 %**: el decil superior concentra 220 conversiones, con una tasa de 48,6 % y un lift de 4,21.
- **Top 20 %**: contactando al 20 % mejor rankeado se captura el 59,7 % de las conversiones.
- **Umbral operativo**: el beneficio esperado es 6.258 frente a 5.899 de contactar a todos (+359, 6,1 %).

Tabla 13. Sensibilidad V/C en test (umbrales elegidos con train).

V/C	Umbral (elegido en OOF)	% contactado	% conversiones	Beneficio modelo	Beneficio contactar a todos	Diferencia
5	0,165	15,5 %	54,5 %	718	-1.916	2.634
10	0,110	23,3 %	62,4 %	2.195	689	1.506
20	0,050	61,1 %	86,6 %	6.258	5.899	359
50	0,023	97,3 %	99,6 %	21.549	21.529	20



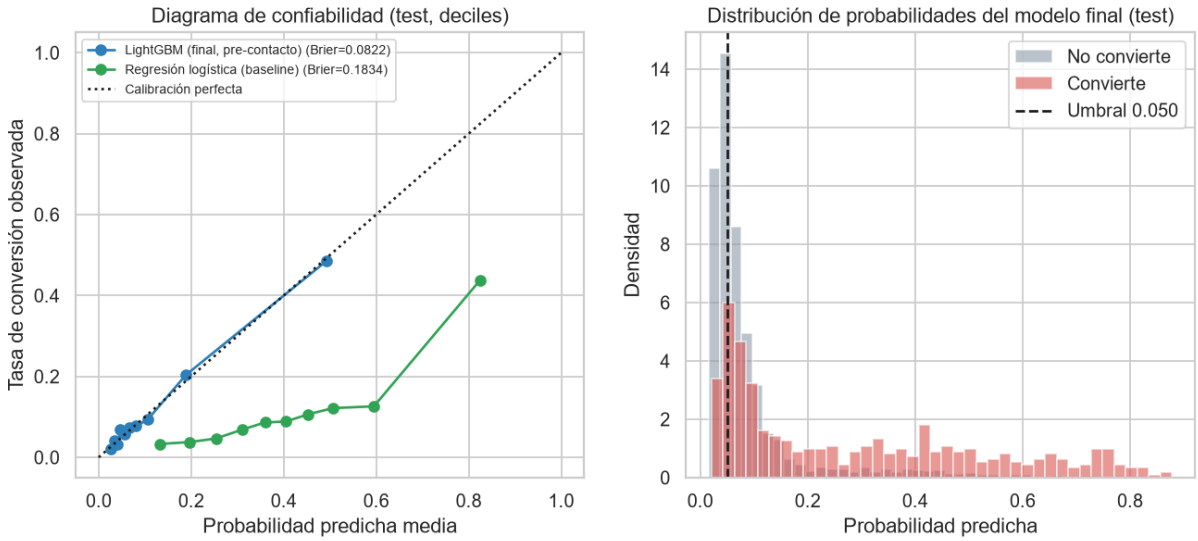
Curvas de beneficio

El valor del modelo depende del ratio V/C:

V/C	Contactar a todos	Modelo	Lectura
5	-1.916 (pérdida)	718	El modelo convierte una pérdida en ganancia
10	689	2.195	El modelo triplica el beneficio
50	—	—	Conviene contactar a casi todos (el modelo contacta al 97,3 %)

Cuando existe un presupuesto fijo de contactos, lo relevante es la calidad del ranking.

5.4 Calibración



Calibración

LightGBM (Brier 0,082): las probabilidades siguen de cerca la diagonal, lo que permite usarlas para estimar conversiones y beneficio esperados.

Regresión logística con pesos de clase (Brier 0,183): sobreestima sistemáticamente la probabilidad. Por ese motivo su umbral óptimo es 0,275.

5.5 Cuantificación del leakage

Tabla 14. Pre-contacto vs con `duration` (test).

Modelo	ROC-AUC	PR-AUC	Lift@10 %	Gain@20 %
LightGBM (final, pre-contacto)	0,784	0,435	4,21	59,7 %
LightGBM + duration (leakage)	0,933	0,607	5,48	83,3 %

Magnitud del efecto:

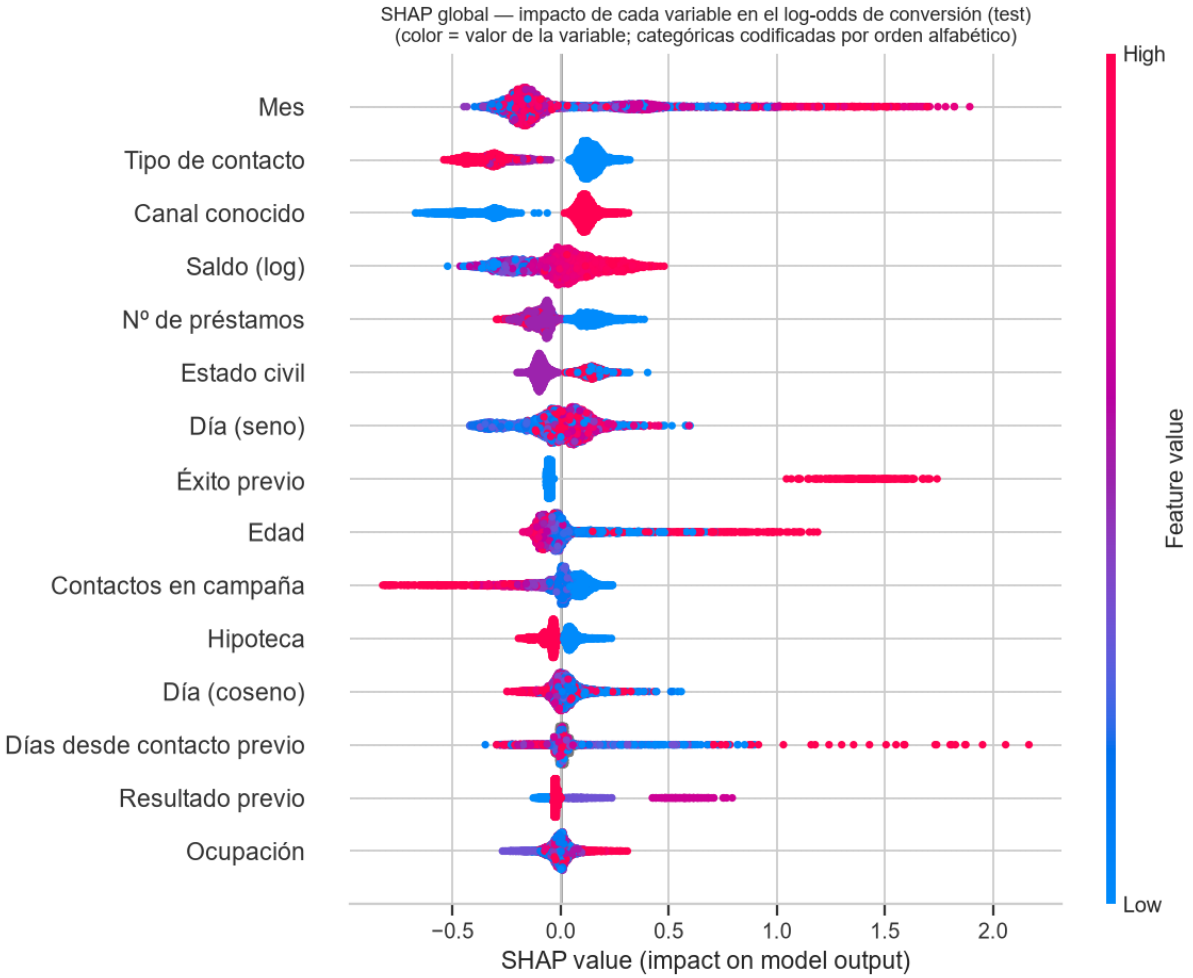
Métrica	Pre-contacto	Con `duration`
ROC-AUC en test	0,784	0,933
ROC-AUC en CV	0,806	0,937

Por qué la mejora es engañosa:

- Para conocer la duración es necesario haber realizado la llamada, que es justamente lo que el modelo debe decidir.
- La relación causal está invertida: la llamada es larga porque el cliente está interesado.

Un modelo con `duration` exhibiría métricas excelentes en validación y no podría utilizarse en producción.

5.6 Explicabilidad



SHAP global

Tabla 15. Importancia global (media del valor absoluto de SHAP, test).

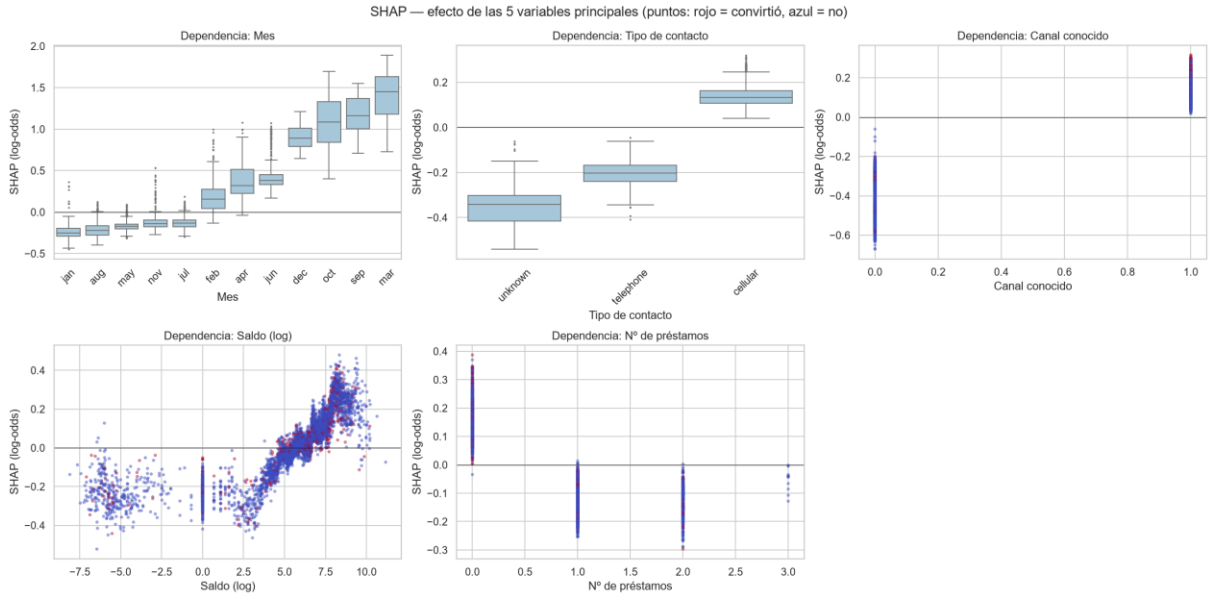
Variable	Media	SHAP		% de la importancia
Mes	0,2641	14,9 %		
Tipo de contacto	0,2062	11,6 %		
Canal conocido	0,1944	11,0 %		
Saldo (log)	0,1362	7,7 %		
Nº de préstamos	0,1194	6,7 %		
Estado civil	0,1125	6,3 %		
Día (seno)	0,1070	6,0 %		
Éxito previo	0,0944	5,3 %		
Edad	0,0912	5,1 %		
Contactos en campaña	0,0893	5,0 %		

Variables más influyentes:

- **Mes** (14,9 %):

- marzo, septiembre, octubre y diciembre aumentan fuertemente la probabilidad;
- enero, mayo y agosto la reducen;
- como se observó en el EDA, refleja la operación y el período. Es el principal riesgo al aplicar el modelo en campañas futuras.

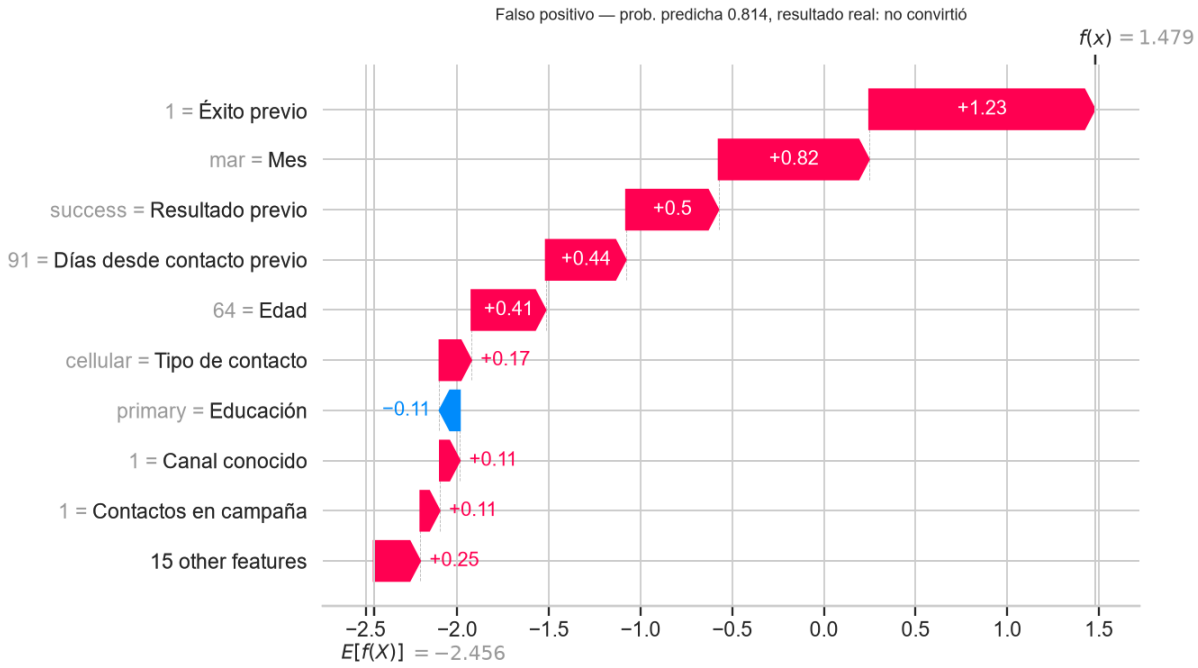
- **Canal de contacto** (22,6 %, entre `contact` y `contact_known`): unknown reduce la probabilidad.
- **Saldo**: tiene un efecto creciente a partir de saldos positivos.
- **Préstamos**: tener uno o más reduce la probabilidad.
- **Éxito en la campaña anterior**: afecta a pocos clientes, pero con un efecto muy grande.
- **Cantidad de contactos en la campaña**: un número alto la reduce.



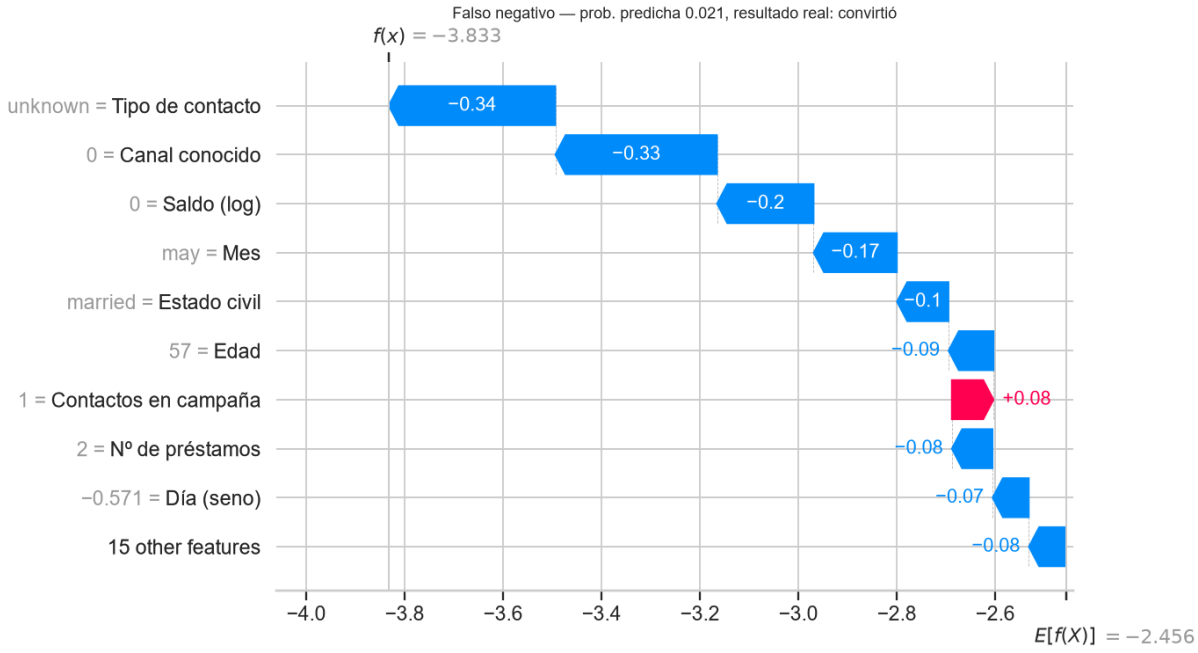
Dependencias SHAP

Explicaciones locales:

- **Verdadero positivo típico**: su probabilidad se explica principalmente por el mes (octubre) y la ausencia de préstamos.
- **Falso positivo de mayor probabilidad**: un jubilado con éxito en la campaña anterior, contactado en marzo. Todas las señales indicaban conversión, por lo que el error es razonable.
- **Falso negativo de menor probabilidad**: un cliente con contacto unknown en mayo, saldo cero y dos préstamos, es decir, el perfil de menor conversión del dataset.



Falso positivo



Falso negativo

Contraste con la regresión logística. Los coeficientes de mayor magnitud también corresponden al mes, al grupo de 65 años o más y al saldo. La coincidencia entre dos familias de modelos da confianza en que las relaciones son reales.

Tabla 16. Coeficientes principales de la regresión logística.

Variable	Coeficiente	Odds ratio
month_mar	1,024	2,78

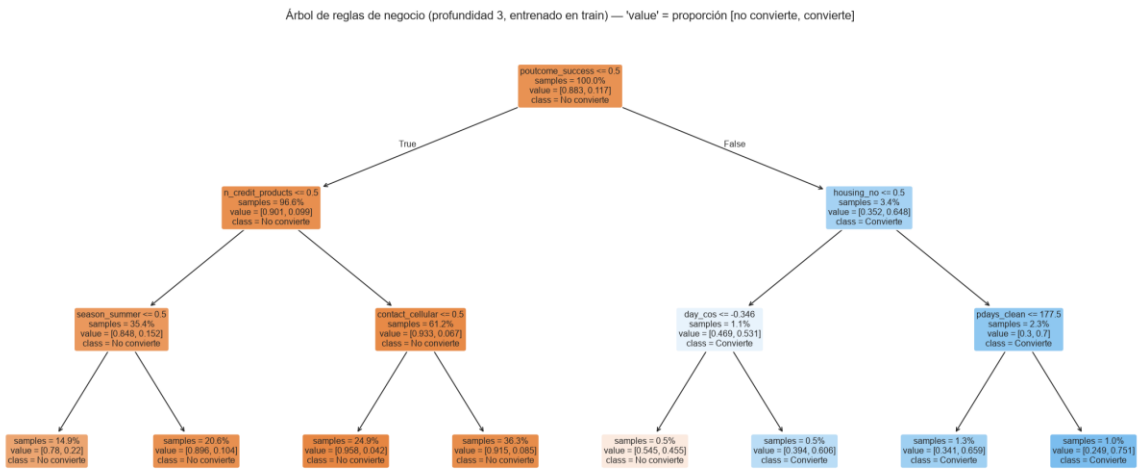
month_nov	-0,981	0,37
month_dec	0,944	2,57
age_group_65+	0,940	2,56
month_jan	-0,845	0,43
month_oct	0,666	1,95
month_may	-0,611	0,54
month_sep	0,551	1,74
month_aug	-0,455	0,63
month_jun	0,430	1,54
balance_log	0,391	1,48
prev_campaign_success	0,370	1,45

Reglas de negocio. Un árbol de profundidad 3 entrenado con train (ROC-AUC en test 0,675) resume las reglas en un formato comunicable:

- éxito en la campaña anterior y sin hipoteca → más del 65 % de conversión;
- sin éxito previo, con préstamos y contacto no celular → alrededor del 4 %.

Tabla 17. Reglas del árbol de profundidad 3.

Regla	Clientes (train)	% del train	Tasa de conversión	Lift
poutcome = success Y housing = no Y pdays_clean > 177.500	426	1,0 %	75,1 %	6,41
poutcome = success Y housing = no Y pdays_clean <= 177.500	525	1,3 %	65,9 %	5,62
poutcome = success Y housing = yes Y day_cos > -0.346	218	0,5 %	60,6 %	5,17
poutcome = success Y housing = yes Y day_cos <= -0.346	213	0,5 %	45,5 %	3,89
poutcome != success Y n_credit_products <= 0.500 Y season != summer	6.048	14,9 %	22,0 %	1,88
poutcome != success Y n_credit_products <= 0.500 Y season = summer	8.369	20,6 %	10,4 %	0,89
poutcome != success Y n_credit_products > 0.500 Y contact = cellular	14.759	36,3 %	8,5 %	0,72
poutcome != success Y n_credit_products > 0.500 Y contact != cellular	10.132	24,9 %	4,2 %	0,36



Árbol de reglas

5.7 Análisis de errores y por segmento

Tabla 18. Perfil de aciertos y errores (test).

Grupo	Clientes	Edad media	Saldo medio	Contactos campaña	% contactados antes	Prob. media
TP	451	42,5	1.729	2,06	39,2 %	0,325
FN	70	42,5	563	3,57	10,0 %	0,039
FP	2.311	40,3	1.761	2,40	19,6 %	0,131
TN	1.689	41,9	914	3,50	10,6 %	0,036

Falsos negativos. Se parecen a los verdaderos negativos:

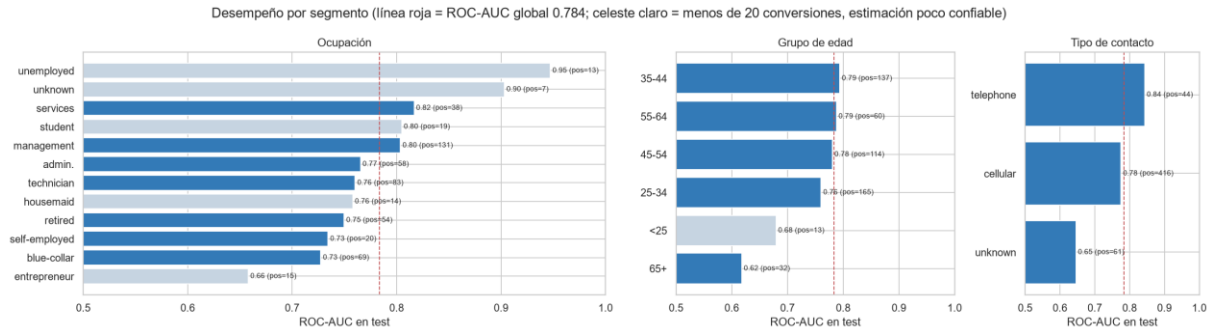
Rasgo	Falsos negativos	Verdaderos positivos
Contacto unknown	61 %	4 %
Contactados en mayo	49 %	13 %
Saldo medio	563	1.729
Contactos en la campaña	3,6	2,1
Contactados antes	10 %	39 %

Son conversiones que ocurrieron dentro de campañas masivas sin señales previas que las distingan.

Tabla 19. Desempeño por segmento (segmentos con al menos 20 conversiones).

Variable	Segmento	Clientes	Conversiones	Tasa	ROC-AUC	Recall al umbral
age_group	65+	89	32	36,0 %	0,618	1,000
age_group	25-34	1.405	165	11,7 %	0,760	0,891
age_group	45-54	1.008	114	11,3 %	0,781	0,789
age_group	55-64	496	60	12,1 %	0,788	0,850
age_group	35-44	1.456	137	9,4 %	0,794	0,869
contact	unknown	1.324	61	4,6 %	0,646	0,295
contact	cellular	2.896	416	14,4 %	0,775	0,940
contact	telephone	301	44	14,6 %	0,843	0,955
job	blue-collar	946	69	7,3 %	0,727	0,754
job	self-employed	183	20	10,9 %	0,734	0,850
job	retired	230	54	23,5 %	0,750	0,889
job	technician	768	83	10,8 %	0,760	0,831
job	admin.	478	58	12,1 %	0,765	0,862

job	management	969	131	13,5 %	0,804	0,916
job	services	417	38	9,1 %	0,817	0,868



Métricas por segmento

Segmentos con peor desempeño:

- **contact = unknown**: ROC-AUC 0,65, 1.324 clientes y 4,6 % de conversión.
- **Mayores de 65 años**: ROC-AUC 0,62. Convierten mucho en promedio (36,0 %), pero el modelo discrimina poco dentro del grupo.

Para esos segmentos convendría incorporar información adicional.

5.8 Razonabilidad de los resultados

Tabla 20. Chequeos de razonabilidad.

Chequeo	Valor	Referencia	Cumple
ROC-AUC sin duration vs referencia 0,75–0,80	0,784	0,75–0,80 (rango de referencia del enunciado para este dataset sin duration)	Sí
ROC-AUC con duration (leakage) en rango típico alto	0,933	> 0,90 esperado: duration por sí sola tiene ROC-AUC ≈ 0,81 en train	Sí
PR-AUC muy por encima del azar (prevalencia)	0,435	piso = prevalencia en test (0.115)	Sí
Modelo final supera a la regresión logística	0,435	PR-AUC logística = 0.3494	Sí
PR-AUC en test dentro de ±2 desvíos de la CV	0,435	CV = 0.4660 ± 0.0201	Sí

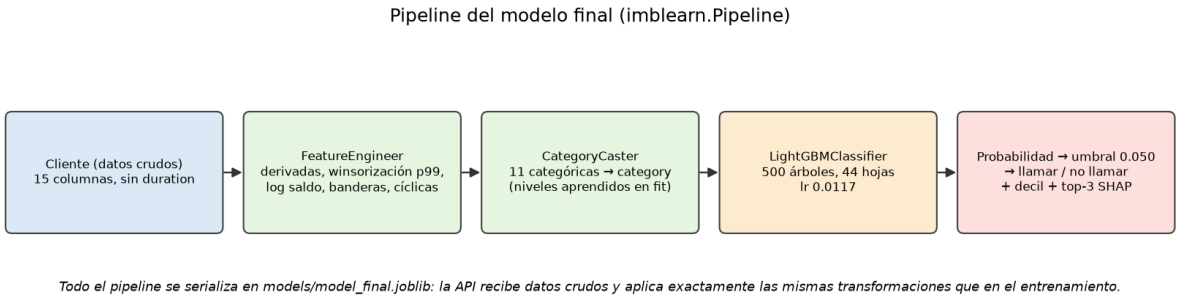
Se cumplen 5 de 5 chequeos:

- El ROC-AUC en test (0,784) está dentro del rango de referencia de 0,75–0,80 para este dataset sin `duration`.
- La inclusión de `duration` lleva el valor por encima de 0,93.
- Un modelo pre-contacto con ROC-AUC mayor a 0,90 habría sido una señal de fuga de información.

6. Despliegue

El modelo final se serializó como un único pipeline (`models/model_final.joblib`) junto con su metadata (`models/metadata.json`). La metadata incluye:

- hiperparámetros;
- métricas de validación cruzada;
- umbral;
- cortes de deciles;
- hash de los datos;
- versiones de las librerías.



Pipeline del modelo final

API REST con FastAPI (`app/api/main.py`, documentación automática en `/docs`):

Endpoint	Función
`GET /health`	Estado del servicio
`GET /model/info`	Metadata del modelo
`POST /predict`	Recibe un cliente en JSON y devuelve la probabilidad, la recomendación, el decil, las tres variables SHAP de mayor peso y una explicación en texto
`POST /predict/batch`	Recibe un CSV y devuelve el mismo CSV rankeado con probabilidad, decil y recomendación

La validación de las entradas se realiza con pydantic:

- enumeraciones para las variables categóricas;
- rangos para las numéricas;
- consistencia entre `pdays` y `previous`;
- **rechazo explícito de duration**.

Interfaz con Streamlit (`app/ui/streamlit_app.py`). Consume la API a través de la variable de entorno `API_URL` y tiene dos pestañas:

- **Cliente individual**: formulario, resultado y explicación.
- **Campaña**:
  - carga de un CSV y ranking;
  - selección del porcentaje de clientes o del presupuesto;
  - conversiones y beneficio esperados;

- descarga del listado priorizado.

Contenedores. El `Dockerfile` y el `docker-compose.yml` levantan la API y la UI. También se documenta la ejecución local sin Docker.

Pruebas. La suite de tests automáticos (`pytest`) verifica:

- las transformaciones de variables;
- la ausencia de fugas: `duration` fuera del modelo e independencia entre train y test;
- la consistencia del modelo y de la metadata;
- todos los endpoints de la API, incluido el rechazo de `duration`.

7. Conclusiones y trabajo futuro

Conclusiones:

1. Con la información disponible **antes** del contacto es posible priorizar clientes con un poder de discriminación moderado y consistente: ROC-AUC 0,784, PR-AUC 0,435 y lift de 4,21 en el decil superior.
2. El valor de negocio depende del cociente entre el valor de una conversión y el costo de un contacto:
    - es alto cuando las llamadas son caras o el presupuesto es limitado;
    - es marginal cuando conviene contactar a casi todos.
3. Las decisiones metodológicas más relevantes no fueron algorítmicas sino de tratamiento de los datos:
    - detectar y eliminar el solapamiento entre train y test;
    - excluir `duration`;
    - preferir probabilidades calibradas en lugar de técnicas de rebalanceo.
4. Los ensambles de árboles superan a los modelos lineales, pero la mejora por tuning es pequeña: el límite lo impone la información disponible.

Limitaciones y trabajo futuro:

- **Temporalidad.** Los datos son una serie temporal (2008–2010) con un fuerte drift en la tasa de conversión, y la partición provista es aleatoria. Antes de usar el modelo en campañas nuevas se recomienda:
    - validar con un esquema temporal;
    - monitorear el efecto de `month`.
- **Parámetros económicos.** Reemplazar los supuestos de C y V por valores reales del banco.
- **Nuevas fuentes de información.** Incorporar variables transaccionales y de relación con el cliente para mejorar los segmentos con peor desempeño.
- **Uplift modeling.** Estimar el efecto causal de la llamada, en lugar de la probabilidad de conversión, requeriría datos de un grupo de control no contactado.

Anexos

Anexo A. Registro de decisiones (decision log)

Decision log

Registro de cada decisión metodológica del trabajo. Formato: **contexto**, **alternativas**, **elección**, **justificación** y **evidencia** (tabla o figura generada por el pipeline).

Fase 0 — Datos

D01 · Eliminación del solapamiento entre train y test

- **Contexto.** Al comparar los archivos se detectó que las **4.521 filas de banca_test.csv (100 %) aparecen idénticas en banca_train.csv**. Los archivos corresponden al dataset *Bank Marketing* de UCI: `banca_train` = `bank-full.csv` (45.211 filas) y `banca_test` = `bank.csv` (4.521 filas), que es una muestra del 10 % de bank-full.
- **Alternativas.** (a) Usar los archivos tal cual. (b) Descartar `banca_test` y armar un hold-out propio desde train. (c) Quitar de train las filas que están en test.
- **Elección.** (c): train pasa de 45.211 a **40.690 filas**; test queda con sus 4.521.
- **Justificación.** Con (a) el modelo vería durante el entrenamiento exactamente los casos con los que después se lo evalúa: las métricas del hold-out serían optimistas y no medirían generalización (un árbol profundo o un KNN con k=1 casi "memorizarían" el test). La opción (b) desaprovecha el archivo de test que provee la consigna. La (c) respeta la consigna, conserva el 90 % de los datos para entrenar y garantiza un hold-out independiente.
- **Evidencia.** `reports/tables/data_preparation_steps.csv` (paso 6), `reports/tables/data_summary.csv` (`test_rows_found_in_train = 4521`); el código verifica con un `assert` que tras la limpieza el solapamiento es 0 (`data.py`).

D02 · Naturaleza de la partición: aleatoria, no temporal

- **Contexto.** bank-full está ordenado cronológicamente (mayo 2008 a noviembre 2010). Si el test fuera un corte temporal habría que evitar features que usen información del futuro y validar con un esquema temporal.
- **Alternativas.** Tratar la partición como temporal (validación *walk-forward*) o como aleatoria (validación cruzada estratificada).
- **Elección.** Aleatoria → `StratifiedKFold` de 5 folds.
- **Justificación.** Las posiciones de las filas de test dentro del archivo de train son compatibles con una distribución uniforme (Kolmogorov-Smirnov: D = 0,014, p = 0,37; posición media relativa 0,495, se esperaría ~1 si fuera el final). Las distribuciones de `month` (χ^2 p = 0,47), `contact` (p = 0,54), `poutcome` (p = 0,20) y del target (p = 0,72) no difieren entre train limpio y test.
- **Evidencia.** `reports/tables/split_checks.csv`.
- **Limitación a documentar.** Aunque la partición es aleatoria, los datos reales son una serie temporal (2008–2010, crisis financiera). Un despliegue real requeriría validar sobre un período posterior; con esta partición no es posible medir la degradación temporal.

D03 · Faltantes codificados, no nulos

- **Contexto.** No hay valores nulos (NaN) en ningún archivo. La información faltante está codificada como la categoría unknown (`job` 0,6 %, `education` 4,1 %, `contact` 28,8 %, `poutcome` 81,7 % en train) y como `pdays = -1` (cliente nunca contactado).
- **Elección.** unknown se mantiene como **categoría propia**; no se imputa a la moda.
- **Justificación.** El faltante no es aleatorio: por ejemplo, `poutcome = unknown` equivale a "sin campaña previa", y `contact = unknown` se concentra en los primeros meses del registro. Imputar destruiría esa información. La evidencia bivariada (tasa de conversión por categoría) se presenta en la Fase 2.
- **Evidencia.** `reports/tables/data_profile.csv` (columna `pct_unknown`).

D04 · Seguimiento de las transformaciones sobre los datos

- **Elección.** Todo paso que modifica o verifica filas queda en `reports/tables/data_preparation_steps.csv`, y todo paso que crea o transforma columnas queda en `reports/tables/feature_catalog.csv` (Fase 3). La explicación narrativa completa está en `docs/03_preparacion_datos.md`.

Fase 1 — Negocio

D05 · Enfoque de ranking y métricas primarias

- **Contexto.** El problema de negocio es priorizar a quién llamar con presupuesto limitado.
- **Alternativas.** Evaluar como clasificador (accuracy, F1 a umbral 0,5) o como ranking (PR-AUC, lift/gain).
- **Elección.** Ranking: PR-AUC y lift/gain al 10/20/30 % como métricas primarias.
- **Justificación.** Ver `docs/01_negocio.md`: con 88,3 % de negativos, accuracy premia al modelo trivial; PR-AUC y lift miden directamente lo que el banco necesita.

D06 · Parámetros económicos C = 1, V = 20

- **Elección.** C = 1, V = 20 (umbral económico teórico $p > 0{,}05$) con sensibilidad $V/C \in \{5, 10, 20, 50\}$.
- **Justificación.** Son supuestos explícitos y parametrizados; el análisis de sensibilidad muestra cómo cambia la decisión si el banco usa valores reales.

Fase 3 — Preparación de los datos

D07 · Variables derivadas

Cada variable, su origen y su justificación están en `reports/tables/feature_catalog.csv`. Resumen:

Variable	Decisión	Evidencia del EDA
`previously_contacted`, `pdays_clean`	Separar la bandera "nunca contactado" del número de días (NaN si -1)	Las 33.249 filas con pdays = -1 son exactamente las de previous = 0; conversión 9,2 % vs 23,1 %
`campaign_w`, `previous_w`	Winsorizar al p99 **aprendido en cada fold** (en train completo: campaign ≤ 17, previous ≤ 9)	Máximo de 63 contactos; cola larga
`balance_log`, `balance_negative`, `balance_zero`	Log con signo + banderas; **no se eliminan outliers**	Asimetría 8,5; 10,4 % de outliers IQR que son saldos reales
`age_group`	Bins además de la edad numérica	Conversión alta en < 25 y 65+
`contact_known`, `prev_campaign_success`	Banderas binarias	contact = unknown: 4,0 %; poutcome = success: 64,8 %
`season`, `day_sin`, `day_cos`	Estación y codificación cíclica del día	Meses con poco volumen; el día 31 está al lado del 1

`n_credit_products`	housing + loan + default	Los préstamos reducen la conversión

- **Alternativa descartada: eliminar outliers de balance.** Se perdería un 10 % de clientes reales y el modelo no sabría puntuarlos en producción.
- **Alternativa descartada: imputar unknown a la moda.** Ver D03.
- **Nota técnica.** La bandera se llamó inicialmente `poutcome_success`, pero ese nombre chocaba con la columna one-hot de la categoría `success` de `poutcome`. Se renombró a `prev_campaign_success`. La redundancia con la columna one-hot no afecta a los árboles; en la logística queda absorbida por la regularización L2.

D08 · Preprocesamiento por familia de modelo

- **Lineales, KNN, MLP y SVM**: imputación por mediana (solo afecta a `pdays_clean`), `StandardScaler` y one-hot con `handle_unknown='ignore'` (67 columnas). Estos modelos son sensibles a la escala.
- **Árboles y boosting con one-hot**: imputación con -1 y sin escalado, porque los árboles son invariantes a transformaciones monótonas.
- **LightGBM y XGBoost con categorías nativas**: las categóricas pasan como dtype `category` y los NaN quedan sin imputar.
- **Naive Bayes**: numéricas continuas discretizadas en quintiles y categóricas ordinales, porque CategoricalNB requiere variables discretas.
- **Todo dentro de un Pipeline**, ajustado solo con los folds de entrenamiento. El modelo final recibe datos crudos; la API no reimplementa el preprocesamiento.

D09 · Dos conjuntos de variables

- `pre_contact` (entregable): 24 variables, **sin duration**. `FeatureEngineer` descarta `duration` aunque venga en los datos (lo verifica `tests/test_leakage.py`).
- `with_duration`: la misma configuración más `duration`, solo para cuantificar el leakage (D18).

Fase 4 — Modelado

D10 · Protocolo de validación

- `StratifiedKFold(5, shuffle=True, random_state=42)` sobre las 40.690 filas.
- Todos los modelos usan exactamente la misma partición (`reports/tables/cv_folds.csv`).
- Se reporta media ± desvío por fold (`cv_results.csv`, `cv_results_folds.csv`).

D11 · Algoritmos comparados (10) y por qué

Modelo	Familia	Por qué se prueba	PR-AUC CV
Dummy (prior)	Referencia	Piso: PR-AUC = prevalencia	0,117
Regresión logística (balanced)	Lineal	Baseline interpretable	0,412 ± 0,012
Árbol de decisión (prof. 6)	Árboles	Reglas explicables	0,351 ± 0,020
KNN (k = 51)	Instancias	No paramétrico, por similitud	0,401 ± 0,020
Naive Bayes categórico	Probabilístico generativo	Simple y rápido; referencia	0,395 ± 0,019
Random Forest	Bagging	Robusto, baja varianza	0,446 ± 0,023
LightGBM	Boosting	Estado del arte en datos tabulares	**0,457 ± 0,020**
XGBoost (scale_pos_weight)	Boosting	Boosting regularizado	0,454 ± 0,021
MLP (64-32)	Redes neuronales	Representante de redes neuronales	0,430 ± 0,020
SVM RBF (submuestra 10k)	Kernels	Frontera no lineal de máximo	0,362 ± 0,020

		margen	

La SVM tiene costo $O(n^2)$, por eso se entrenó sobre una submuestra estratificada de 10.000 filas. Se evalúa sobre el fold de validación completo usando `decision_function`, así que no tiene Brier.

D12 · Codificación de categóricas en boosting

- **LightGBM**: la codificación nativa (0,4580) superó al one-hot (0,4567) → se usa **nativa**.
- **XGBoost**: el one-hot (0,4541) superó a la nativa (0,4509) por más de la tolerancia de 0,003 → se usa **one-hot**.
- Evidencia: `encoding_comparison.csv`.

D13 · Estrategia de desbalance

- **Contexto.** Se compararon tres estrategias sobre los 3 mejores modelos (LightGBM, XGBoost y Random Forest):
  - (a) sin tratamiento, con ajuste de umbral;
  - (b) pesos de clase;
  - (c) SMOTE dentro del pipeline.
- **Resultados.**

Modelo	Métrica	(a) Sin tratamiento	(b) Pesos	(c) SMOTE
LightGBM	PR-AUC	0,459	0,458	0,455
LightGBM	Brier	0,081	0,144	0,082
Random Forest	PR-AUC	0,451	0,446	0,436

- **Elección. (a) sin tratamiento + ajuste de umbral**, para los tres modelos.
- **Justificación.**
  - Las diferencias de PR-AUC son menores que un desvío entre folds.
  - Los pesos de clase **descalibran** las probabilidades: el Brier casi se duplica. El umbral y el beneficio esperado dependen de probabilidades bien calibradas.
  - SMOTE interpola clientes sintéticos sobre variables one-hot, algo que no tiene interpretación, y además empeora al Random Forest.
  - Regla aplicada: si la diferencia de PR-AUC es menor a 0,003, se prefiere la estrategia que no distorsiona las probabilidades.
- **Evidencia.** `imbalance_results.csv`, `imbalance_comparison.png`.

D14 · Tuning

- **Método.** Optuna con sampler TPE (semilla 42), 60 trials por modelo y tope de 15 minutos. El objetivo es la PR-AUC media en los mismos 5 folds.
- **Resultados.**
  - LightGBM: de 0,4589 a **0,4660** (≈ 67 s).
  - XGBoost: de 0,4522 a 0,4629.
- **Mejores hiperparámetros de LightGBM.** n_estimators 500, learning_rate 0,0117, num_leaves 44, min_child_samples 20, subsample 0,68, colsample_bytree 0,63 y regularización L1/L2 baja.

- **Espacios de búsqueda.** `models.suggest_params`.
- **Evidencia.** `tuning_summary.csv`, `tuning_trials_*.csv`, `tuning_convergence_*.png`.
- **Limitación.** La PR-AUC del mejor trial es optimista porque se eligió mirando los mismos folds. La estimación sin sesgo es la del hold-out.

D15 · Selección final (matriz de decisión)

- **Criterios y pesos.**
  - PR-AUC: 35 %
  - lift@20 %: 25 %
  - estabilidad (desvío de PR-AUC): 15 %
  - interpretabilidad (escala 1–5): 15 %
  - velocidad de inferencia: 10 %
- **Normalización.** Min-max entre candidatos.
- **Puntaje ponderado.**

Candidato	Puntaje
LightGBM tuneado	**0,690**
XGBoost tuneado	≈ 0,65–0,67
XGBoost por defecto	≈ 0,64–0,65
LightGBM por defecto	0,632
Regresión logística	0,400

- **Evidencia.** `decision_matrix.csv`.
- **Nota de reproducibilidad.** Todas las métricas son idénticas entre ejecuciones (semilla 42). La única excepción es el tiempo de inferencia, que depende de la carga de la máquina, por lo que los puntajes de los candidatos no ganadores varían en la segunda o tercera cifra decimal. LightGBM tuneado gana en todas las ejecuciones: tiene la mejor PR-AUC y el mejor lift, y su puntaje no depende de la velocidad, porque es el más lento de los candidatos de boosting.
- **Por qué no la logística.** Es la más estable e interpretable, pero pierde 0,05 de PR-AUC (≈ 12 % relativo) y 0,3 de lift@20 %. La interpretabilidad de LightGBM se recupera con SHAP.

D16 · Umbral operativo

- **Método.** Se eligió con las predicciones out-of-fold del modelo final, maximizando $V \cdot TP - C \cdot (TP+FP)$ con $V = 20$ y $C = 1$.
- **Umbral elegido: 0,050.** Coincide con el umbral teórico C/V, lo que indica probabilidades bien calibradas.
  - En OOF contacta al 61,9 %, con recall 0,891 y beneficio 59.772.
  - Contactar a todos daría 54.670.
- **Umbral que maximiza F1: 0,215.**
  - Contacta al 13,4 % y el beneficio baja a 45.363.
  - F1 pondera igual precisión y recall, e ignora que una conversión vale 20 veces una llamada.
- **Evidencia.** `threshold_choice.json`, `threshold_analysis.csv`, `sensitivity_oof.csv`, `threshold_selection.png`.

Fase 5 — Evaluación

D17 · Uso único del hold-out

- `evaluate.py` y `explain.py` son los únicos módulos que leen el test.
- Cargan el modelo, los hiperparámetros y el umbral ya fijados en la Fase 4.
- El umbral de la logística se eligió con sus propias predicciones OOF de train.
- Ninguna decisión se tomó después de ver los resultados de test.
- Evidencia: `reports/tables/holdout_usage.json`, que registra fecha y hash del modelo evaluado.

D18 · Cuantificación del leakage

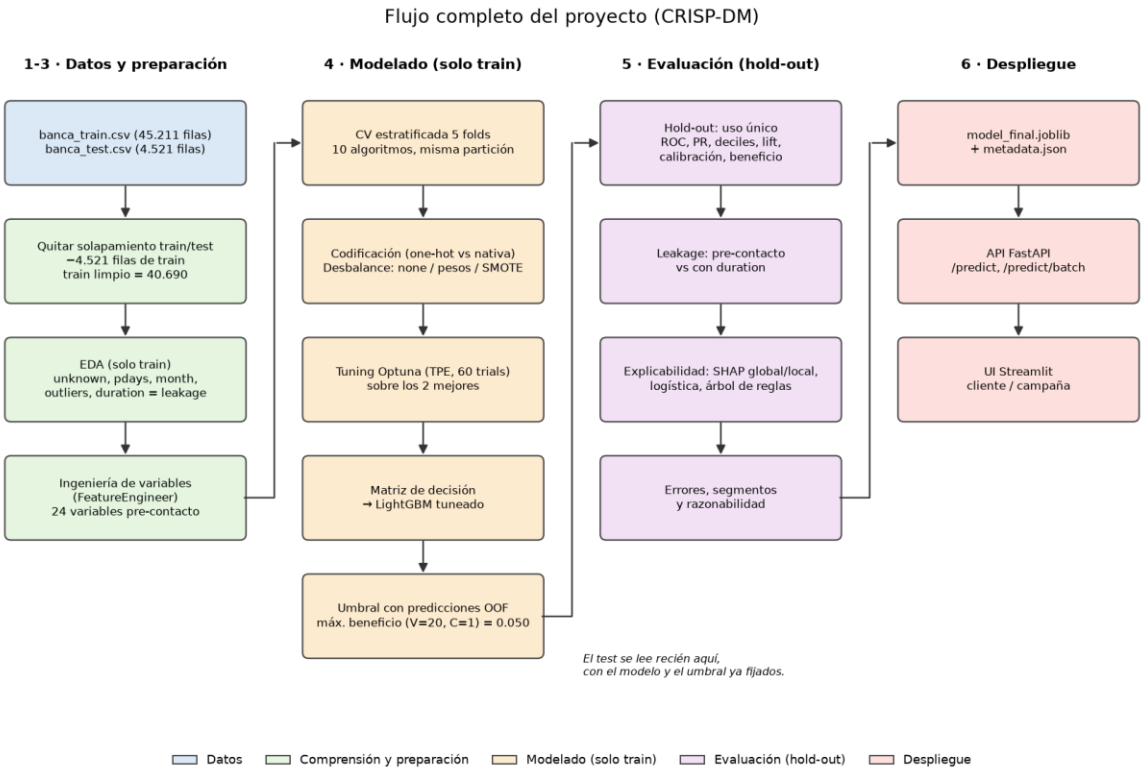
Conjunto	ROC-AUC CV	PR-AUC CV	ROC-AUC test	PR-AUC test
pre_contact (entregable)	0,806	0,466	0,784	0,435
with_duration	0,937	0,638	0,933	0,607

El modelo con `duration` **no se entrega**. Evidencia: `leakage_cv.csv`, `test_leakage.csv`.

D19 · Advertencia sobre `month`

- `month` es la variable más importante (15 % de la importancia SHAP).
- El EDA mostró que refleja el volumen de la operación y el período, no una característica del cliente.
- Se mantiene porque se conoce antes de llamar y la partición es aleatoria.
- Se recomienda monitorear su efecto y reentrenar con datos recientes antes de usar el modelo en campañas nuevas.

Anexo B. Diagrama del flujo completo



Flujo del proyecto

Anexo C. Instrucciones de reproducción

```
python -m venv .venv
.venv\Scripts\activate            # Windows  (macOS: source .venv/bin/activate)
pip install -r requirements.txt
pip install -e .
# copiar banca_train.csv y banca_test.csv en data/raw/
python -m bank_captacion.pipeline # reconstruye datos, EDA, modelos, evaluación, notebooks e informe
python -m pytest -q               # tests
python -m uvicorn app.api.main:app --port 8000
python -m streamlit run app/ui/streamlit_app.py
```

Todas las tablas completas están en `reports/tables/` y todas las figuras en `reports/figures/`.